




Instrucciones de Proyecto (Competencia)

Curso Aprendizaje de Máquina 2026-20

1. Introducción

Bienvenidos al proyecto del curso. El presente proyecto consiste en una competencia académica en la que participarán grupos de todas las secciones. El desafío propuesto consiste en desarrollar un sistema de **clasificación de sentimiento** de reseñas de productos escritas en español. El objetivo principal es diseñar un modelo capaz de predecir, dado un párrafo de reseña, si la opinión global del cliente es **negativa, neutral o positiva**.

Aparentemente sencilla, la tarea esconde una dificultad interesante: muchas reseñas contienen simultáneamente elogios y quejas (“*la batería es excelente, pero la cámara resultó decepcionante*”). El sentimiento global no se obtiene simplemente contando palabras positivas y negativas: depende del **orden**, de la **negación** y de los **conectores contrastivos**. Esto convierte al problema en un excelente banco de pruebas para comparar representaciones de texto clásicas con modelos secuenciales profundos.

La competencia se divide en dos etapas. En la primera, los participantes deberán emplear técnicas tradicionales de aprendizaje automático, sin recurrir al uso de redes neuronales ni arquitecturas profundas. En la segunda etapa, será obligatorio utilizar redes neuronales profundas, así como implementar estrategias de aumento de datos.

La competencia es exclusiva para estudiantes del Curso de Aprendizaje de Máquina de la Universidad de los Andes inscritos en el semestre 2026-20.

2. Resultados de Aprendizaje

Con esta actividad se busca que el estudiante pueda poner en práctica el desarrollo de una solución completa de *machine learning* para un problema de clasificación de texto. Tras realizar esta actividad se espera que el estudiante esté en capacidad de:

1. Proponer y seleccionar modelos de *machine learning* que permitan resolver un problema de clasificación de texto.
2. Identificar y aplicar diferentes técnicas de procesamiento de texto.
3. Representar el texto de manera que permita el uso de modelos de *machine learning*.

4. Hacer uso de los datos para entrenar y evaluar el desempeño del modelo.
5. Probar distintos modelos para encontrar la mejor solución para el problema particular.
6. Comprender las limitaciones de las representaciones de tipo bolsa de palabras frente a los modelos que capturan el orden de las palabras.

3. Descripción de la Competencia

La competencia consiste en la construcción de un sistema capaz de clasificar reseñas de productos según el sentimiento global expresado. El objetivo principal es desarrollar un modelo que, dado un párrafo como entrada, prediga de manera precisa una de las tres clases: **negativo**, **neutral** o **positivo**.

3.1. Plataforma

Kaggle es una plataforma en línea que permite a investigadores, profesionales y estudiantes participar en competencias de ciencia de datos y aprendizaje automático. En Kaggle, los usuarios pueden acceder a conjuntos de datos, desarrollar modelos, colaborar con otros participantes y presentar sus soluciones para ser evaluadas automáticamente mediante un sistema de puntuación. Además, ofrece recursos educativos y foros de discusión que facilitan el aprendizaje y la resolución de problemas. Para la competencia del curso se utilizará la plataforma Kaggle. En un documento anexo publicado en Bloque Neón va a encontrar un tutorial de registro a la plataforma, registro a una competencia de prueba y la explicación de cómo realizar envíos.

3.2. Descripción de los Datos

Se proporcionan los siguientes archivos:

- **train.csv**: contiene 12,000 ejemplos de entrenamiento con columnas:
 - **id** (int): identificador único del ejemplo.
 - **text** (str): texto de la reseña a clasificar.
 - **label** (str): sentimiento del texto. Toma uno de tres valores: **negativo**, **neutral** o **positivo**.
- **eval.csv**: archivo de evaluación con 3,000 ejemplos y columnas:
 - **id**: identificador único del ejemplo de prueba.
 - **text**: texto de la reseña a clasificar.
- **sample_submission.csv**: ejemplo del formato de envío.

3.3. Archivo de respuesta

El archivo de respuesta debe contener el siguiente formato:

```
id,answer
0,positivo
1,negativo
2,neutral
...
```

Cada **id** en el conjunto de prueba debe tener un valor en la columna **answer**, indicando el sentimiento predicho por el modelo.

Este archivo de respuesta debe ser enviado a través de la plataforma Kaggle, y será utilizado para la evaluación de su propuesta, así como para su clasificación en el leaderboard de la competencia. La métrica de evaluación es la **exactitud (accuracy)** de clasificación. Una parte de los resultados se empleará para calcular el score público, el cual estará disponible durante toda la competencia, mientras que otra parte se utilizará para el score privado, que determinará el resultado final y será revelado un día después de la finalización de la competencia.

4. Parte 1: Machine Learning Clásico

La primera etapa de la competencia se centra en la aplicación de algoritmos clásicos de aprendizaje automático para la tarea de clasificación.

4.1. Requisitos técnicos

Recuerde que su modelo no tendrá validez si no cumple los requisitos que se mencionan a continuación. Por lo tanto, obtendrá una calificación de 0 en la primera entrega. Los requisitos son los siguientes:

- No se permite el uso de técnicas de aprendizaje profundo, incluyendo modelos de lenguaje basados en arquitecturas *transformer* ni *embeddings* preentrenados de redes neuronales.
- Únicamente se pueden emplear modelos de clasificación desarrollados con la librería **scikit-learn**, siempre que no contravengan los demás requisitos aquí establecidos.
- La competencia debe resolverse exclusivamente mediante el uso de modelos clásicos de aprendizaje automático y técnicas de representación de texto abordadas durante la primera parte del curso (por ejemplo, *bag-of-words*, TF-IDF, n-gramas).
- Para la revisión en Bloque Neón, se debe subir un único modelo, el cual debe corresponder al envío que haya obtenido el mejor resultado en la competencia de Kaggle de su grupo.
- Los resultados deben ser completamente replicables a partir de los entregables presentados en la plataforma de Bloque Neón.

4.2. Entregables en Bloque Neón

En la semana 11 del curso se habilitará una actividad en la que usted y su grupo deberán subir los siguientes entregables, correspondientes únicamente al modelo final con el que obtuvieron los mejores resultados en la tabla de líderes pública de la competencia de Kaggle:

1. Jupyter Notebook que se utilizó para realizar la implementación y el entrenamiento del clasificador de texto.
2. El archivo donde se guardó el modelo de **scikit-learn** entrenado. El modelo debe guardarse haciendo uso de las librerías **pickle** o **joblib**.

4.3. Rúbrica de Evaluación

La nota del proyecto se compone de los siguientes criterios:

Cuadro 1: Composición de la nota del proyecto - Parte 1

Item	Porcentaje de la nota
Desarrollo	
Documentación en el Notebook del modelo creado	15 %
Calidad del proceso seguido para la construcción del modelo	15 %
Aporte individual al proyecto	15 %
Sustentación de lo realizado	15 %
Competencia	
Participación en la competencia	15 %
Superar la línea base (ver en Kaggle)	10 %
Percentil obtenido en la competencia	15 %

4.3.1. Participación en la competencia

Para que sea considerada su participación en la competencia su grupo debe realizar al menos 5 envíos **diferentes** en la plataforma de Kaggle. La idea es evidenciar que el grupo trató de mejorar su enfoque inicial.

4.3.2. Superar la línea base

El equipo del curso preparó una línea base (i.e. modelo) que debe superar. Esta línea base la encuentra en el leaderboard de la competencia en Kaggle.

4.3.3. Percentil obtenido en la competencia

El 15 % correspondiente a este rubro se obtiene de acuerdo al desempeño del modelo desarrollado con su grupo en la competencia de Kaggle. Al cerrar la competencia se generan unos puntajes finales, y su nota en este rubro dependerá del desempeño obtenido. El porcentaje obtenido de este rubro se calcula de la siguiente manera:

Desempeño obtenido	Porcentaje del rubro
< percentil 25	0 %
≥ percentil 25 y < percentil 50	50 %
≥ percentil 50 y < percentil 75	75 %
> percentil 75	100 %

Cuadro 2: Distribución del porcentaje del rubro según desempeño obtenido

4.3.4. Fechas Importantes Parte 1

- Fecha de apertura: **Semana 2**
- Fecha de finalización: **Semana 9**

4.4. Enlaces de la Competencia Kaggle Parte 1

- **Enlace de Invitación:** *(será publicado en Bloque Neón)*

5. Parte 2: Deep Learning y Aumentación de Datos

En esta segunda etapa de la competencia, usted y su grupo deberán abordar la tarea de clasificación utilizando arquitecturas profundas de aprendizaje automático. Se permite emplear modelos de aprendizaje profundo como MLPs, redes neuronales convolucionales (CNN), recurrentes (RNN, LSTM, GRU), entre otras.

¿Por qué el aprendizaje profundo debería ayudar? Como el sentimiento global depende del orden de las cláusulas (recencia, negación, conectores contrastivos), un modelo que *procesa la secuencia* —en lugar de tratar el texto como una bolsa de palabras— puede capturar información que la Parte 1 no alcanza. Se espera, por tanto, una mejora medible respecto a la línea base clásica.

5.1. Requisitos técnicos

Para esta parte, es fundamental cumplir con los siguientes requisitos para que su modelo sea considerado válido:

- Es obligatorio el uso de técnicas y arquitecturas de aprendizaje profundo. Se permite (y se recomienda explorar) transferencia de aprendizaje y modelos o *embeddings* preentrenados.
- Es **obligatorio** aplicar al menos una estrategia de aumentación de datos y documentar su efecto sobre el desempeño.
- Se permite el uso de datos externos siempre que la licencia lo autorice, puedan ser referenciados adecuadamente, descargados y distribuidos.
- En caso de utilizar datos adicionales, estos deben ser referenciados de manera clara, incluyendo la página de donde fueron obtenidos y la licencia explícita de uso.
- Está permitido el uso de datos sintéticos para entrenar los modelos, pero debe describir en detalle cómo realizó la construcción.
- Está estrictamente prohibido utilizar los datos de prueba (eval) para el entrenamiento de los modelos.

5.2. Entregables en Bloque Neón

En la semana 14 del curso se habilitará una actividad en la que usted y su grupo deberán subir los siguientes entregables, correspondientes únicamente al modelo final con el que obtuvieron los mejores resultados en la tabla de líderes pública de la competencia de Kaggle:

1. Jupyter Notebook utilizado para la implementación, entrenamiento y evaluación del modelo de aprendizaje profundo. Este Notebook debe incluir el análisis y justificaciones de los pasos y las decisiones más importantes que llevan a tener como mejor modelo el propuesto. Esto incluye evidencia clara de iteración (cambios en modelos, features o parámetros que llevaron a una mejora) y la comparación del desempeño con y sin aumentación de datos.
2. El archivo con el modelo entrenado, guardado utilizando las librerías vistas en clase (**tensorflow**, **keras**, etc.).
3. Un documento adicional que incluya las referencias a los datos externos utilizados, especificando la fuente, el enlace y la licencia de cada conjunto de datos. Además debe incluir el uso dado a la IA generativa en el desarrollo del proyecto.

5.3. Rúbrica de Evaluación

La nota del proyecto se compone de los siguientes criterios:

Cuadro 3: Composición de la nota del proyecto - Parte 2

Item	Porcentaje de la nota
Desarrollo	
Documentación en el Notebook del modelo creado	15 %
Calidad del proceso seguido para la construcción del modelo	15 %
Aporte individual al proyecto	15 %
Sustentación de lo realizado	15 %
Competencia	
Participación en la competencia	15 %
Superar la línea base (ver en Kaggle)	10 %
Percentil obtenido en la competencia	15 %

5.3.1. Fechas Importantes Parte 2

- Fecha de finalización: **Semana 16**

5.4. Enlaces de la Competencia Kaggle Parte 2

- **Enlace de Invitación:** *(será publicado en Bloque Neón)*